Estadística

Unidad 1

Clase 2: Medidas de ubicación y dispersión



Objetivos

Comprender y aplicar las principales medidas estadísticas para caracterizar conjuntos de datos. Calcular e interpretar medidas de tendencia central y variabilidad para resumir información numérica y evaluar la dispersión de los datos respecto a su centro.



Bloques Temáticos

- Medidas de ubicación
  - Media aritmética y sus propiedades de transformación
  - Mediana como valor central robusto
  - Moda como valor más frecuente
  - Percentiles y cuartiles
  - Medias especiales (geométrica, armónica, cuadrática)
- Medidas de variabilidad
  - Rango
  - Varianza y desviación estándar muestral
  - Propiedades de transformación de medidas de dispersión

UNIDAD 1

ESTADÍSTICA

1.1 Medidas de ubicación

Los resúmenes visuales de datos son herramientas excelentes para obtener impresiones y percepciones preliminares. Un análisis de datos más formal a menudo requiere el cálculo e interpretación de medidas resumidas numéricas. Es decir, de los datos se trata de extraer varios números que podrían servir para caracterizar el conjunto de datos y comunicar algunas de sus características prominentes.

Cualquier magnitud numérica calculable a partir de los datos se denomina estadístico.

Supongamos entonces que el conjunto de datos es de la forma $x_1, \ldots, x_n$ donde cada x_i es un número. Una importante característica de un conjunto de números es su ubicación y en particular su centro.

1.1.1 Media aritmética.

Un estadístico usado para indicar el centro de un conjunto de datos $x_1, \ldots, x_n$ es la **media muestral**, definida como la media artimética de los valores de datos. Más precisamente,

Definición 1.1.1. La media muestral, denotada por $\overline{x}$, se define por:

$$\overline{x} = \frac{\sum_{i=1}^{n} x_i}{n} = \frac{x_1 + x_2 + \cdots + x_n}{n}$$

Ejemplo 1.1.2. Las eficiencias en el consumo de carburante (medidas en número de kilómetros recorridas por litro de carburante) de los coches vendidos en Estados durante los años 1999 y 2003 tuvieron como promedio:

28.2 28.3 28.4 28.5 29

Encontrar la media de este conjunto de datos.

Solución.

La media muestral $\overline{x}$ coincide con la media aritmética de los cinco valores de datos. Así pues,

$$\overline{x} = \frac{28.2 + 28.3 + 28.4 + 28.5 + 29}{5} = \frac{142.4}{5} = 28.48$$

□

Observemos a partir de este ejemplo que, aunque la media muestral es la media aritmética de los distintos valores de datos, no tiene por qué coincidir con ninguno de éstos.

La media sufre una deficiencia que la hace ser una medida inapropiada del centro en algunas circunstancias: su valor puede ser afectado en gran media por la presencia de incluso un solo valor extremo; esto es una observación inusualmente grande o pequeña. En el ejemplo anterior, si reemplazamos el valor 29 por 100, este último sería un valor extremo y tendríamos que $\overline{x} = 42.68$, el cuál es más grande que todas excepto una de las observaciones.

Consideremos un conjunto de datos $x_1, \ldots, x_n$. Si cada valor de dato se incrementa en una constante c, la media muestral se incrementa igualmente en el valor c. Es decir, si

$$y_i = x_i + c \qquad \text{para } i = 1, \ldots, n$$

se verifica que

$$\overline{y} = \overline{x} + c$$

donde $\overline{y}$ y $\overline{x}$ representan las medias muestrales de los valores y_i y los valores x_i, respectivamente. Por consiguiente, cuando sea conveniente, se puede calcular $\overline{x}$ si se añade, primer, c a todos los valores de datos; después, se calcula la media muestral $\overline{y}$; y finalmente, se resta c a $\overline{y}$ para obtener $\overline{x}$. Puesto que en ocasiones es más sencillo trabajar con los datos transformados en lugar de con los datos originales, el proceso indicado puede simplificar el cálculo de $\overline{x}$. El siguiente ejemplo ilustra este hecho.

Ejemplo 1.1.3. Las puntuaciones obtenidas por los ganadores del Torneo de Maestros de Gol de Estados Unidos entre 1981 y 1990 fueron las siguientes:

$$280, 284, 280, 277, 282, 279, 285, 281, 283, 278$$

Encontrar la media muestral de las puntuaciones anteriores.

Solución.

En vez de sumar directamente todos los valores anteriores, restemos primero 280 (esto es, $c = -280$) de cada uno de ellos. Así se obtienen los siguientes datos transformados:

$$0, 4, 0, -3, 2, -1, 5, 1, 3, -2$$

La media muestral y, de estos últimos valores es

$$\overline{y} = \frac{0+4+0-3+2-1+5+3-2}{10} = \frac{9}{10}$$

Si a $\overline{y}$ le añadimos 280, se obtiene que la media de los datos originales es

$$\overline{x} = 280, 9$$

□

Si cada valor de dato se multiplica por c, igualmente queda multiplicada por c la media resultante. Esto es, si

$$y_i = cx_i \qquad \text{para cada } i = 1, \dots n$$

se verifica que

$$\overline{y} = c \cdot \overline{x}$$

Ejemplo 1.1.4. Supongamos que la media de las alturas de un conjunto de individuos es de 5 pies. Si se quisiera cambiar la unidad de medida de pies a pulgadas, cada nuevo valor coincidiría con el antiguo multiplicado por 12. Se sigue que la media muestral de los datos nuevos coincide con $12 \cdot 5 = 60$. Es decir, la media muestral es de 60 pulgadas.

Supongamos que los datos vienen dados en una tabla de frecuencias, donde se incluyen k valores distintos $x_1, \dots, x_k$ junto con sus respectivas frecuencias $f_1, \dots, f_k$. El conjunto de datos consistirá, pues, en n observaciones, donde $n = \sum_{i=1}^{k} f_i$ y donde cada valor x_i aparece f_i veces, para $i = 1, \dots, k$. Por consiguiente, la media muestral de este conjunto de datos será

$$\overline{x} = \frac{x_1 + \cdots + x_1 + x_2 + \cdots + x_2 + \cdots + x_k + \cdots + x_k}{n} = \frac{\sum_{i=1}^{k} f_i \cdot x_i}{n}$$

Ejemplo 1.1.5. El número de vestidos vendidos diariamente en una boutique de señoras durante los seis últimos días viene expresado en la tabla de frecuencias siguientes:

Valor	Frecuencia
3	2
4	1
5	3

Calcular la media muestral.

Solución.

Dado que el conjunto de datos originales se compone de los siguientes 6 valores

$$3,3,4,5,5,5$$

la media muestral resultante será

$$\begin{aligned}\overline{x} &= \frac{3+3+4+5+5+5}{6} \\ &= \frac{3\cdot 2+4\cdot 1+5\cdot 3}{6} \\ &= \frac{25}{6}\end{aligned}$$

Esto es, la media muestral del número de vestidos vendidos diariamente es de $4.1\widehat{6}$.

1.1.2 Mediana.

Un estadístico que se utiliza también para representar el centro de un conjunto de datos es la **mediana muestral**, definida como el valor medio cuando los datos están ordenados de menor a mayor. La mediana muestral será denotada por m.

Definición 1.1.6. La mediana muestral se obtiene ordenando primero las n observaciones de la más pequeña a la más grande (con cualesquiera valores repetidos incluidos de modo que cada observación muestral aparezca en la lista ordenada). Si el número de datos es impar, la mediana muestral coincide con el valor que se encuentra en la posición central en la lista ordenada; si el número de datos es par, la mediana muestral es la media de los dos valores que ocupan las posiciones centrales.

De esta definición se deduce que, si existen tres valores de datos, la mediana muestral coincide con el segundo valor más pequeño; mientras que, si existen cuatro valores, coincide con la media de los valores más pequeños segundo y tercero.

Ejemplo 1.1.7. Los siguientes datos representan el número de semanas que siete individuos tardaron en obtener su carnet de conducir.

$$2,110,5,7,6,7,3$$

Encontrar la mediana muestral.

Solución.

Ordenamos primero los datos en orden creciente.

$$2,3,5,6,7,7,110$$

Puesto que el tamaño de la muestra es 7, la mediana muestral será el cuarto valor más pequeño. Esto es, la mediana muestral del número de semanas que se tardó en obtener el carnet de conducir es $m = 6$ semanas.

Ejemplo 1.1.8. Los siguientes datos representan el número de días que a seis individuos les costó dejar de fumar tras completar un curso diseñado para este propósito.

$$1,2,3,5,8,100$$

Calcular la mediana muestral.

Solución.

Puesto que el tamaño muestral es 6, la mediana muestral es la media de los dos valores centrales una vez ordenados; así pues,

$$m = \frac{3+5}{2} = 4$$

Es decir, la mediana muestral es de 4 días.

1.1.3 Moda.

Otro indicador de la tendencia central es la *moda muestral*, que se define como el valor de dato que aparece con mayor frecuencia en un conjunto de datos.

Ejemplo 1.1.9. Los siguientes datos se refieren a las tallas de los últimos 8 vestidos vendidos en una boutique de mujeres.

$$8, 10, 6, 4, 10, 12, 14, 10$$

¿Cuál es la moda muestral?

Solución.

La moda muestral es 10, puesto que este es el valor que ocurre con mayor frecuencia.

Si no existe un único valor que aparezca con mayor frecuencia en el conjunto de datos, aquellos valores que tengan la máxima frecuencia se denominan *valores modales*. En esta situación se dice que no existe un valor único de la moda muestral.

Ejemplo 1.1.10. Las edades de 6 niños de una guardería son las siguientes:

$$2, 5, 3, 5, 2, 4$$

¿Cuáles son los valores modales de este conjunto de datos?

Solución.

Puesto que las edades 2 y 5 son las que ocurren con mayor frecuencia, estos dos valores (2, y 5) son los modales.

Resulta muy sencillo obtener el valor modal a partir de una tabla de frecuencias, puesto que coincide con aquel valor que tenga mayor frecuencia.

Ejemplo 1.1.11. La siguiente tabla de frecuencias muestra los valores obtenidos en 30 lanzamientos de un dado.

Valor	Frecuencia
1	6
2	4
3	5
4	8
5	3
6	4

Para estos datos, encontrar:

a) La moda muestral.

b) La mediana muestral.

c) La media muestral.

Solución.

a) Puesto que el valor 4 aparece con la mayor frecuencia, la moda muestral es 4.

b) Puesto que existen 30 valores de datos, la mediana muestral coincide con la media entre el 15° y 16° valor menor. Puesto el 15° valor menor es 3 y el 16° valor menor es 4, la mediana muestral es 3,5.

c) La media muestral es

$$\overline{x} = \frac{1 \cdot 6 + 2 \cdot 4 + 3 \cdot 5 + 4 \cdot 8 + 5 \cdot 3 + 6 \cdot 4}{30} = \frac{100}{30} \approx 3,33$$

Comparación entre media, mediana y moda. En distribuciones simétricas, la media, mediana y moda tienden a coincidir. En distribuciones asimétricas, la media se ve más afectada por valores extremos, mientras que la mediana y la moda son más robustas. Por ello, es importante considerar estas tres medidas en conjunto para interpretar adecuadamente los datos.

Ejemplo 1.1.12. En una encuesta a 10 hogares sobre su gasto mensual en plataformas de streaming (en dólares): 10, 15, 12, 15, 20, 15, 30, 25, 15, 50.

- Media: $\bar{x} = \frac{207}{10} = 20.7$

- Mediana: 15 (valor central tras ordenar los datos)
- Moda: 15 (aparece 4 veces)

Esto muestra cómo los valores extremos (como 50) afectan la media, pero no la mediana ni la moda.

1.1.4 Percentiles muestrales

La mediana muestral divide el conjunto de datos en dos partes iguales. Para obtener medidas de ubicación más finas, se podrían dividir los datos en más de dos partes.

Definición 1.1.13. El **percentil muestral de orden 100p por ciento**, donde p es un número comprendido entre 0 y 1, es aquel valor de dato que tiene la propiedad de que al menos el $100p$ por ciento de los valores de datos son menores o iguales que él y que al menos el $100(1-p)$ por ciento de los valores de datos son mayores o iguales que él. Si existen dos valores de datos que cumplen las condiciones anteriores, el percentil muestral de orden $100p$ por ciento se define como la media aritmética de ambos valores de datos.

Supongamos que se han ordenado de menores a mayor todos los valores de datos de una muestra tamaño n. Para determinar el percentil muestral de orden $100p$ por ciento se debe encontrar aquel valor que verifica que:

1. Al menos np valores de datos son menores o iguales que él.
2. Al menos $n(1-p)$ valores de datos son mayores o iguales que él.

Ahora bien, si np no es un entero, el único valor de dato que cumple ambos puntos es aquel cuya posición de orden coincide con el primer entero superior a np. Por ejemplo, supongamos que se quiere determinar el percentil muestral de orden 90 % en una muestra de tamaño $n = 12$. Puesto que $p = 0.9$, se tiene que

$$np = 10.8 \qquad \text{y} \qquad n(1-p) = 1.2.$$

Así pues, se estarán buscando aquellos valores para los que:

1. Al menos 10.8 valores de datos sean menores o iguales que él (por consiguiente, el valor de datos debe estar en la posición de orden 11 o mayor).
2. Al menos 1.2 valores de datos sean mayores o iguales que él (por tanto, debe ocupar la posición de orden 11 o menores).

Evidentemente, el único valor de dato que cumple ambos puntos es aquél que ocupa la posición de orden 11 y, en consecuencia éste será el percentil muestral de orden 90 %.

Por otro lado, si np es un número entero, tanto el valor de dato que ocupa la np posición de orden como el valor de dato que ocupa la posición de orden $np + 1$ cumplen las condiciones de las definiciones 1 y 2; en este caso, el percentil muestral de orden $100p$ por ciento será igual a la media aritmética de los dos valores de datos anteriores. Por ejemplo, supongamos que se desea encontrar el percentil muestral de orden 95 % en un conjunto de datos con $n = 20$ valores. En este caso, tanto el 19° valor como el 20° valor

serán mayores o iguales que al menos $np = 20 \cdot (0.95) = 19$ de los valores de datos, y serán menores o iguales que al menos $n(1-p) = 1$ de dichos valores. El percentil muestral de orden 95 % será, pues, la media aritmética de los valores que ocupan las posiciones de orden 19 y 20.

Resumiendo, se ha demostrado lo siguiente:

Proposición 1.1.14. *Para encontrar el percentil muestral de orden $100p$ % de un conjunto de datos de tamaño n:*

1. *Ordenamos los datos en sentido creciente.*
2. *Si np no es un número entero, determinamos el menor entero mayor que np. El valor de dato que ocupa la posición de orden igual a este último entero será el percentil muestral de orden $100p$ por ciento.*
3. *Si np es un entero, el percentil muestral de orden $100p$ por ciento coincidirá con la media aritmética de los valores que ocupan las posiciones de orden np y $np+1$.*

Ejemplo 1.1.15. Calcular el percentil muestral de orden 90 % cuando el tamaño muestral es:

a) 8 **b)** 16 **c)** 100

Solución.

a) Puesto que $0,9 \cdot 8 = 7,2$ no es un entero, si se ordenan los datos de menor a mayor, el percentil muestral de orden 90 % coincidirá con el octavo valor menor (es decir, el mayor de todos).

b) Puesto que $0,9 \cdot 16 = 14,4$ no es un entero, el percentil muestral de orden 90 % será el 15° valor menor.

c) Puesto que $0,9 \cdot 100 = 90$ es un entero, el percentil muestral de orden 90 % coincidirá con la media aritmética de los valores que ocupan las posiciones 90 y 91 una vez que los datos han sido ordenadas de menor a mayor.

Los percentiles muestrales de órdenes 25, 50 y 75 % se conocen como cuartiles.

Definición 1.1.16. El percentil muestral de orden 25 % se llama *primer cuartil*. El percentil muestral de orden 50 % se denomina *mediana* o *segundo cuartil*. El percentil muestral de orden 75 % se llama *tercer cuartil*.

Los cuartiles dividen el conjunto de datos en cuatro partes, de forma que, aproximadamente, un 25 % de los valores de datos se encuentran por debajo del primer cuartil, otro 25 % de los valores se encuentra entre el primer y el segundo cuartil, un tercer 25 % se encuentra entre el segundo y el tercer cuartil y, por último, el 25 % restante de los valores supera al tercer cuartil.

Ejemplo 1.1.17. Encontrar los cuartiles muestrales para los siguientes 18 valores de datos, que se muestran ordenados y representan las puntuaciones de una liga de bolos.

122	126	133	140	145	145	149	150	157
162	166	175	177	177	183	188	199	212

Solución.

Puesto que $0,25 \cdot 18 = 4,5$, el percentil muestral de orden 25 % coincide con el quinto valor menor, que es 145.

Dado que $0,50 \cdot 18 = 9$, el segundo cuartil (o mediana muestral) es igual a la media del noveno y décimo valor menor, es decir, su valor es:

$$\frac{157 + 162}{2} = 159,5$$

Finalmente, puesto que $0,75 \cdot 18 = 13,5$, el tercer cuartil coincide con el 15° valor menor, que es 177.

1.1.5 Medias geométrica, armónica y cuadrática

Existen otras definiciones de media que pueden tener su utilidad en algunos casos. La primera de estas es la *media geométrica* $\overline{x_G}$. En el caso de una muestra con n valores $x_1, \ldots, x_n$ se define como la raíz $n-$ésima del producto de los valores de la variable

$$\overline{x_G} = \sqrt[n]{x_1 \cdot x_2 \cdots x_n}$$

Esta media tiene la característica negativa de que si uno de los valores es nulo, la media sería asimismo cero, y por lo tanto sería poco representativa del valor central. Además, si existen valores negativos es posible que no se pueda calcular.

La *media armónica* $\overline{x_A}$ se define como la inversa de la media aritmética de los inversos de los valores de datos. Es decir, para $x_1, x_2, \ldots, x_n$

$$\overline{x_A} = \frac{n}{\sum_{i=1}^{n} \frac{1}{x_i}}$$

Es claro que si una de las medidas es 0, la media armónica no tiene sentido.

Una tercera definición corresponde a la *media cuadrática* $\overline{x_Q}$. Se define esta como la raíz cuadrada de la media aritmética de los cuadrados de los valores:

$$\overline{x_Q} = \sqrt{\frac{\sum_{i=1}^{n} x_i^2}{n}}$$

Esta media tiene su utilidad con frecuencia en la aplicación a fenómenos físicos.

Se puede demostrar que estas medias se relacionan con la media aritmética, en el caso de valores positivos de los datos, por

$$\overline{x_A} \leq \overline{x_G} \leq \overline{x} \leq \overline{x_Q}$$

La media armónica es poco sensible a valores muy altos de x, mientras que a la media cuadrática le afectan los valores muy bajos de la variable.

Ejemplo 1.1.18. Supongamos que la siguiente tabla corresponde a una serie de medidas experimentales

x_i	9.77	9.78	9.80	9.81	9.83	10.25
y_i	-3	-2	0	1	3	45

Media aritmética

$$\overline{x} = \frac{\sum_{i=1}^{6} x_i}{6} = \frac{9.77 + 9.78 + \cdots + 10.25}{6} = 9.873$$

Media geométrica

$$\overline{x_G} = \sqrt[6]{x_1 x_2 \ldots x_6} = \sqrt[6]{9.77 \times 9.78 \times \cdots \times 10.25} = 9.872$$

Media armónica

$$\overline{x_A} = \frac{6}{\sum_{i=1}^{6} \frac{1}{x_i}} = \frac{6}{\frac{1}{9.77} + \frac{1}{9.78} + \cdots + \frac{1}{10.25}} = 9.871$$

Media cuadrática

$$\overline{x_Q} = \sqrt{\frac{\sum_{i=1}^{6} x_i^2}{6}} = \sqrt{\frac{9.77^2 + 9.78^2 + \cdots + 10.25^2}{6}} = 9.875$$

1.2 Medidas de variabilidad

Las medidas de centralización vistas anteriormente reducen la información recogida de la muestra a un solo valor. Sin embargo, dicho valor central, será más o menos representativo de los valores de muestra dependiendo de la dispersión que las medidas individuales tengan respecto a dicho centro. Para analizar la representatividad de las medidas de

centralización se definen las llamadas medidas de dispersión. Estas nos indicarán la variabilidad de los datos en torno a su valor promedio, es decir si se encuentra muy o poco esparcidos en torno a su centro.

La medida más simple de variabilidad en una muestra es el **rango**, el cual es la diferencia entre los valores muestrales más grandes y más pequeños.

Un defecto del rango, no obstante, es que depende de sólo las dos observaciones más extremas y hace caso omiso de las posiciones de las valores restantes.

Las medidas principales de variabilidad implican las **desviaciones de la media**, $x_1 - \overline{x}, x_2 - \overline{x}, \ldots, x_n - \overline{x}$. Es decir, las desviaciones de la media se obtienen restando $\overline{x}$ de cada una de las n observaciones muestrales. Si todas las desviaciones son pequeñas en magnitud, entonces todas las x_i se aproximan a la media y hay poca variabilidad. Alternativamente, si algunas de las desviaciones son grandes en magnitud, entonces algunas x_i quedan lejos de $\overline{x}$, lo que sugiere una mayor cantidad de variabilidad. Una forma simple de combinar las desviaciones en una sola cantidad es promediarlas. Desafortunadamente, esto es una mala idea ya que la suma de desviaciones es cero:

$$\sum_{i=1}^{n}(x_i - \overline{x}) = 0$$

por lo que la desviación promedia siempre es cero.

Para evitar que las desviaciones negativas y positivas se neutralicen, utilizamos la siguiente medida de variabilidad:

Definición 1.2.1. La **varianza muestral**, denotada por s^2 está dada por

$$s^2 = \frac{\sum(x_i - \overline{x})^2}{n-1}$$

La **desviación estándar muestral**, denotada por s, es la raíz cuadrada (positiva) de la varianza

$$s = \sqrt{s^2}$$

La desviación típica muestral se mide en las mismas unidades que los datos originales. Es decir, si por ejemplo los datos originales están dados en metros de longitud, la varianza muestral vendrá expresada en metros al cuadrado; mientras que la desviación típica muestral vendrá dada en pies.

Ejemplo 1.2.2. Encontrar la varianza muestral y la desviación estándar del siguiente conjunto de datos:

1 2 5 6 6

Solución.

Calculemos, en primer lugar, la media muestral:

$$\overline{x} = \frac{1+2+5+6+6}{5} = 4$$

Luego,

$$\begin{aligned} s^2 &= \frac{(1-4)^2+(2-4)^2+(5-4)^2+(6-4)^2+(6-4)^2}{5-1} \\ &= \frac{9+4+1+4+4}{4} = 5,5 \end{aligned}$$

La desviación estándar es $s = \sqrt{5.5} \approx 2.345$

Llamemos S_{xx} al numerador de s^2. La siguiente identidad algebraica resulta útil cuando se desea calcular a mano la varianza muestral:

$$S_{xx} = \sum_{i=1}^{n} (x_i - \overline{x})^2 = \sum_{i=1}^{n} x_i^2 - n\overline{x}^2$$

con lo cual,

$$s^2 = \frac{S_{xx}}{n-1}$$

Algunas otras propiedades de s^2 pueden mejorar el entendimiento y facilitar el cálculo

Proposición 1.2.3. *Sean $x_1, x_2, \ldots, x_n$ una muestra y c cualquier constante no nula.*

1. *Si $y_j = x_j + c$, para $j = 1, \ldots, n$, entonces $s_y^2 = s_x^2$.*
2. *Si $y_j = cx_j$, para $j = 1, \ldots, n$, entonces $s_y^2 = c^2 s_x^2$ y $s_y = |c| s_x$.*

Donde s_x^2 es la varianza muestral de las x y s_y^2 es la varianza muestral de las y.

Estas propiedades pueden ser comprobadas al observar que en el resultado 1, $\overline{y} = \overline{x} + c$ y que en el resultado 2, $\overline{y} = c\overline{x}$.

Se puede utilizar este resultado, junto con la identidad de S_{xx}, para reducir enormemente el tiempo de cálculo de la varianza muestral.

Ejemplo 1.2.4. Los siguientes datos muestran el número de policías asesinados en actos de servicios en Estados Unidos a lo largo de 10 años.

$$164, 165, 157, 164, 152, 147, 148, 131, 147, 155$$

Encontrar la varianza muestral del número de policías asesinados en esos años.

Solución.

En vez de trabajar directamente con los datos dados, restemos el valor 150 de cada uno de ellos. (Esto es, sumemos $c = -150$ a cada valor de dato). Así se obtiene el conjunto de datos nuevo:

$$14, 15, 7, 14, 2, -3, -2, -19, -3, 5$$

Su media muestral es

$$\overline{y} = \frac{14 + 15 + 7 + 14 + 2 - 3 - 2 - 19 - 3 + 5}{10} = 3$$

La suma de los cuadrados de los datos nueva es

$$\sum_{j=1}^{10} y_j^2 = 14^2 + 14^2 + 7^2 + 14^2 + 2^2 + 3^2 + 2^2 + 19^2 + 3^2 + 5^2 = 1078$$

Así pues, se llega a que

$$S_{yy} = \sum_{j=1}^{10} (y_j - \overline{y})^2 = 1078 - 10 \cdot 9 = 988$$

Por lo tanto, la varianza muestral de los datos nuevos, que coincide con la de los datos originales, es

$$s_x^2 = s_y^2 = \frac{S_{yy}}{9} = \frac{988}{9} \approx 109.78$$

Otro indicador de la variabilidad de un conjunto de datos es el rango intercuartílico, que es igual a la diferencia entre el tercer y el primer cuartil. Esto es, hablando grosso modo, el rango intercuartílico es la longitud del intervalo que contiene la mitad central de los datos.

Ejemplo 1.2.5. El Test de Analogías de Miller es un test estandarizado al que se someten distintos alumnos qu intentan acceder a determinados estudios universitarios y profesionales. La siguiente tabla muestra algunos de los percentiles de las puntuaciones obtenidas por algunos de los estudiantes que se han presentado al test, clasificados por el tipo de estudios que pretenden seguir.

Percentil de orden (en %)	**Ciencias Físicas**	**Medicina**	**Ciencias Sociales**	**Lengua y Literatura**	**Derecho**
99	93	92	90	87	84
90	88	78	82	80	73
75	80	71	74	73	60
50	68	57	61	59	49
25	55	45	49	43	37

Determinar los rangos intercuartílicos para los estudiantes de los cinco tipos de estudios específicos.

Solución.

Puesto que el rango intercuartílico es la diferencia entre los percentiles de órdenes 75 y 25 %, se tendrá que su valor será

- $80 - 55 = 25$ para las puntuaciones de los estudiantes de Ciencias Físicas.
- $71 - 45 = 26$ para las puntuaciones de los estudiantes de Medicina.
- $74 - 49 = 25$ para las puntuaciones de los estudiantes de Ciencias Sociales.
- $73 - 43 = 30$ para las puntuaciones de los estudiantes de Lengua y Literatura.
- $60 - 37 = 23$ para las puntuaciones de los estudiantes de Derecho.

1.3 Ejercicios

1. Los datos siguientes muestran los promedios anuales de lluvia caída (en pulgadas) y de días con precipitación en una muestra de ciudades.

Ciudad	Promedio de lluvia	Promedio de días con precipitación
1	35,74	134
2	31,50	83
3	11,43	95
4	15,31	88
5	19,59	100
6	44,76	105
7	47,29	127
8	12,08	36
9	57,55	129
10	59,74	114
11	36,30	154
12	29,13	81
13	28,61	85

a) Encuentre la media muestral de los promedios de lluvia en pulgadas.

b) Encuentre la media muestral de los promedios de los días con precipitación.

2. Considere cinco números y suponga que la media de los cuatro primeros es 14.

a) Si el quinto número es 24, ¿cuál es la media de los cinco números?

b) Si la media de los cinco números es 24, ¿cuál es el valor del quinto número?

3. Suponga que la media muestral de un conjunto de 10 datos puntuales es $\overline{x} = 20$.

a) Si se descubre que se ha leído incorrectamente un dato con valor 15 y que se le ha dado el valor 13, ¿cuál será el valor revisado de la media muestral?

b) Si existiera un dato adicional con valor 22, ¿aumentaría o disminuiría el valor de $\overline{x}$?

c) Con los datos originales (y no con los datos revisados en el apartado (a)), ¿cuál sería el nuevo valor de $\overline{x}$ del apartado (b)?

4. La siguiente tabla de frecuencias refleja las edades de los componentes de una joven orquesta sinfónica.

Edades	**Frecuencias**
16	9
17	12
18	15
19	10
20	8

Encuentrar la media muestral de las edades dadas.

5. **a)** Determine la mediana muestral del conjunto de datos.

$$14,\ 22,\ 8,\ 19,\ 15,\ 7,\ 8,\ 13,\ 20,\ 22,\ 24,\ 25,\ 11,\ 9,\ 14$$

b) Incremente cada valor de (a) en 5 unidades, y encuentre la nueva mediana muestral.

c) Multiplique por 3 cada valor de (a), y encuentre la nueva mediana muestral.

6. Si la mediana de un conjunto de datos

$$x_i, \quad \text{con } i = 1, \ldots, n$$

es 10, determinar la mediana del conjunto de datos

$$2 \cdot x_i + 3, \quad \text{para } i = 1, \ldots, n$$

7. Encuentre el percentil muestral de orden 90 % del siguiente conjunto de datos.

75	33	55	21	46	98	103	88	35	22	29
73	37	101	121	144	133	52	54	63	21	7

8. Considere los siguientes conjuntos de datos A y B:

$A : 1, 2, 5, 6, 6$ $\qquad\qquad$ $B : -40, 0, 5, 20, 35$

a) Encuentre la varianza muestral de cada uno de los conjuntos A y B.

b) Compruebe que, para el conjunto de datos A, se verifica la siguiente igualdad:

$$\sum_{i=1}^{n}(x_i - \overline{x})^2 = \sum_{i=1}^{n} x_i^2 - n\overline{x}^2$$

9. Los siguientes datos muestran el número de policías asesinados en actos de servicio en Estados Unidos a lo largo de 10 años.

164 165 157 164 152 147 148 131 147 155

Encuentre la varianza muestral del número de policías asesinados en esos años.

10. Encuentre la desviación típica muestral del conjunto de datos reflejado en la siguiente tabla de frecuencias:

Valor	**Frecuencia**
3	1
4	2
5	3
6	2

11. Si s y s^2 son la desviación estándar y varianza muestral de los datos x_i, para $i = 1, ..., n$, ¿cuáles son las desviación estándar y varianza muestral de $y_i = a \cdot x_i + b$, con $i = 1, ..., n$? En este problema, a y b son constantes dadas.